

Meeting 10.09.

Bei only Backdoor bei zwischen 40 und 50% global bessere erkennung

Bei distraction attack Syn-Flood > 50% und 11% backdoor bessere erkennung für Backdoor ebenfalls > 50% syn-flood und 22% Backdoor ebenfalls bessere erkennung für backdoor


Wenn syn-flood unter 50% ist wird backdoor auch schlechter erkannt.

Syn-Flood alleine wird bereits ab 27% besser erkannt.

Sonst kann er grundlegend besser entscheidungen treffen durch die zusätzlichen informationen des Agg reports so korrigiert er seine prognose immer etwas höher oder niedriger je nach informationen der nachbarn.


Man könnte noch richtig geilen shit machen mit mehr angriffsdaten, und nicht einem RF model sondern einem model welches zeitlinien betrachtet, so können backdoor angriffe alleine auch viel besser erkannt werden

Datensatz im gesamt ist wie folgt aufgebaut: Grün: (None/Benign) Rot: (Syn-Flood) Blau: (Backdoor)




Der gemischte Datensatz (Original, DAE, TabGAN) hier Combined Nodes genannt, im vergleich zu den reinen Originalen Datensatz und TabGAN bzw. DAE jeweils alleinstehend:


Feature Correlation Matrices Split by State (Idle vs Charging) — All Nodes Combined



Feature Importance Comparison across Models (Combined Nodes Included)




Model Evaluation Parameters: Original vs DAE vs TabGAN vs Combined Nodes




Nun Die modelle im vergleich Baseline: (Model welches nur die eigenen HW-daten auswertet), Model1: (Nutz eigenen HW-Daten + Hardware und Attack_prob. Daten aus Agg-Report) Model2: (Eigenen HW-Daten, Eigenen Attack_prob, HW und attack_prob daten aus Agg_Report)


Global Confusion Matrix Comparison Across All Pooled Nodes




Multiclass One-vs-Rest ROC Curves Comparison (All Pooled Nodes)



Feature Importance Comparison Across All 3 Model Architectures




Angriffserkennung der verschiedenen Szenarien:



Die ersten Böcke wird einen Distraction syn-flood attack gemacht und nur auf einem ein Backdoor angriff

Danach nochmal das selbe nur das auf 2 Nodes ein Backdoor angriff gefahren wird

Dann ein Syn-Flood DDos angriff der mehrer nodes nach einander angreift
Das selbe mit einem Backdoor Angriff der sich über die zeit auf immer mehr Ladesäulen ausbreitet
Danach eine Cluster Shuffling Syn-Flood Attack
und als letztes none Leistungsschwankungen (grau) (muss ich nochmal anders klassifizieren als "none" oder weglassen)








$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Berechnung des MacroF1-Score:





Wenn None block alles richtig erkannt wird precision = 1.0 , wenn syn-flood alles erkannt wird Precision = 1.0, wenn backdoor nicht vorhanden ist ist es 0*0/0+0, und dann wird der schnitt von allen genommen also

1.0 + 1.0 + 0 / 3 = 0.66 deshalb der schlechte Macro F1-Score






Performance Comparison: Distributed Syn Flood




Performance Comparison: Worm Backdoor




Performance Comparison: Cluster Shuffling Syn Flood




Node A: Model 2 Full Context Comparison & Problem Zone Analysis












Node E: Model 2 Full Context Comparison & Problem Zone Analysis









Daraus kann man lesen sehen das er sich bei der Distraction Backdoor erst sicher ist wenn Syn-Flood avg score hoch ist dann ist er sich auch sicherer wenn seinen eigenen Attack_prob_Backdoor hochgeht, und eine sichere Entscheidung trifft.






Auch hier syn-flood braucht einen deutlichen spike damit er Backdoor angriff und diese art von distraction erkennt. Weiterhin muss man zu gute halten, dass er syn-flood dauerhaft besser erkennt.

Bei Backdoor angriffen über verteiltes netzwerk ist der Sprung erst bei 50% der gesamten nodes infiziert:




Bei Syn-Flood alleine liegt ohne weiteres rauschen ist die erkenntungsrate durch den Agg report sogar noch besser



Die Muster insgesamt ist auch genau das was die bisherigen ergebnisse vermuten lassen, syn-flood hat eine deutliche eigenes cluster und benign zu backdoor unterscheidet sich nur kaum:

Reduction-Based Density Cluster Analysis (PCA + OPTICS)



train test los Baseline RF:

Final Train Log Loss: 0.192623
Final Test Log Loss: 0.201272

Model 1:

Train Log Loss: 0.124317

Global Test Loss: 0.138893

Model 2:

Train Log Loss: 0.066727

Global Test Loss: 0.089103