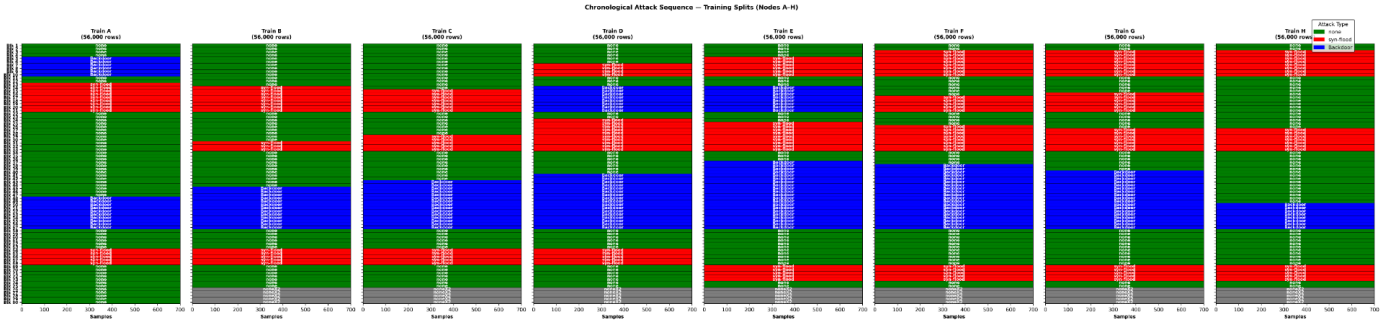
Meeting 10.09.

Bei only Backdoor bei zwischen 40 und 50% global bessere erkennung
Bei distraction attack Syn-Flood > 50% und 11% backdoor bessere erkennung für Backdoor ebenfalls > 50% syn-flood und 22% Backdoor ebenfalls bessere erkennung für backdoor
Wenn syn-flood unter 50% ist wird backdoor auch schelchter erkannt.
Syn-Flood alleine wird bereits ab 27% besser erkannt.

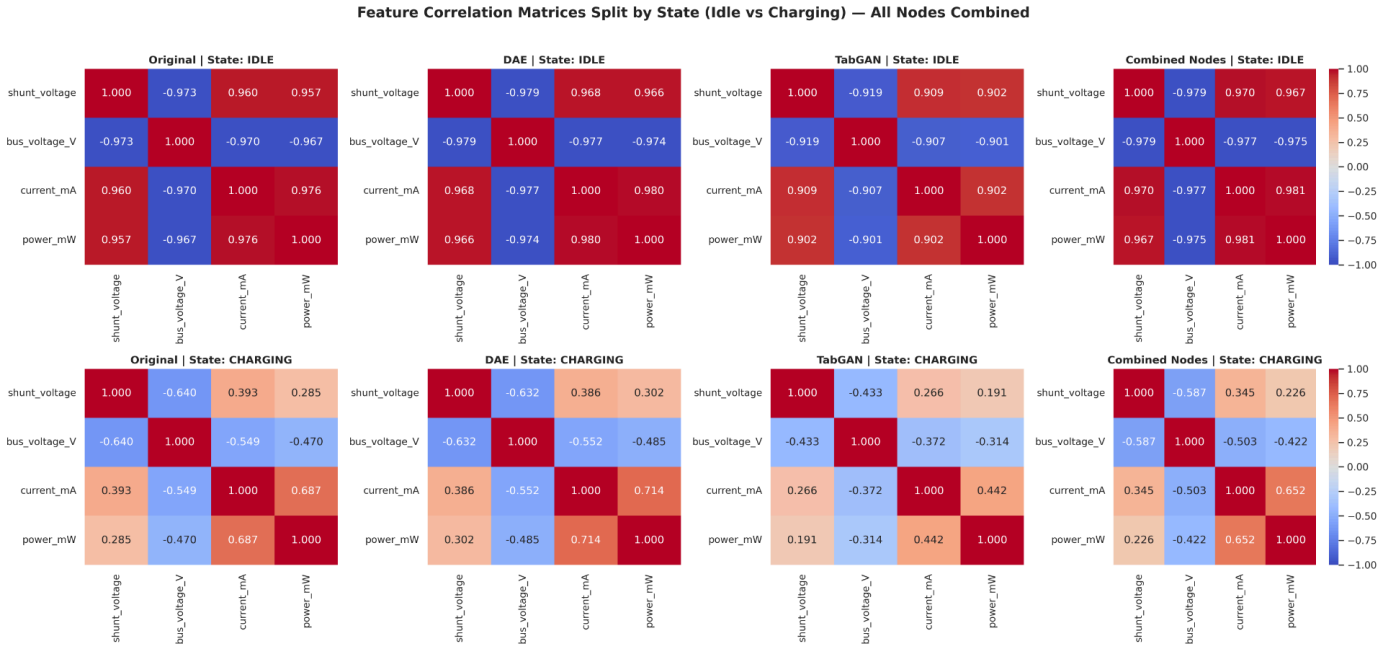
Sonst kann er gurndlegend besser entscheidungen treffen durch die zusätzlichen informationen des Agg reports so korrigiert er seine prognose immer etwas höher oder niedrieger je nach infomrationen der nachbarn.

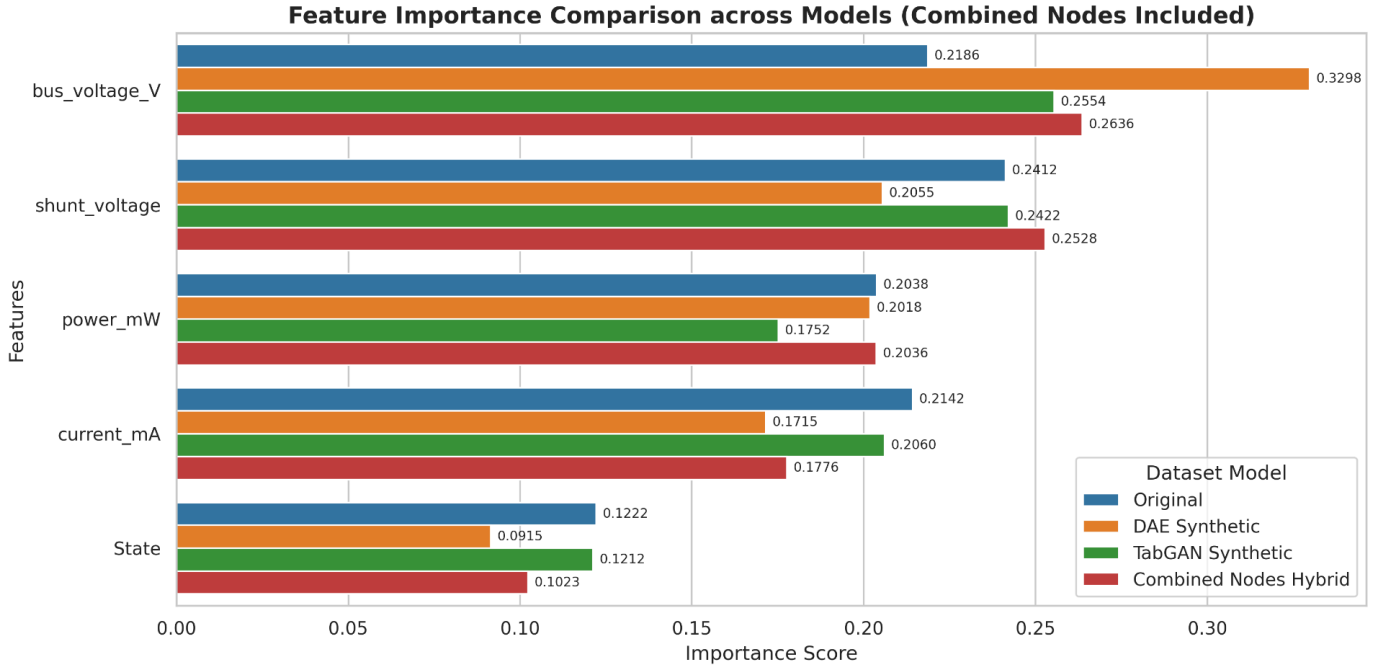
Man könnte noch richtig geilen shit machen mit mehr angriffsdaten, undnicht einem RF model sondern einem model welches zeitlienen betrachtet, so können backdoor angriffe alleine auch viel besser erkannt werden

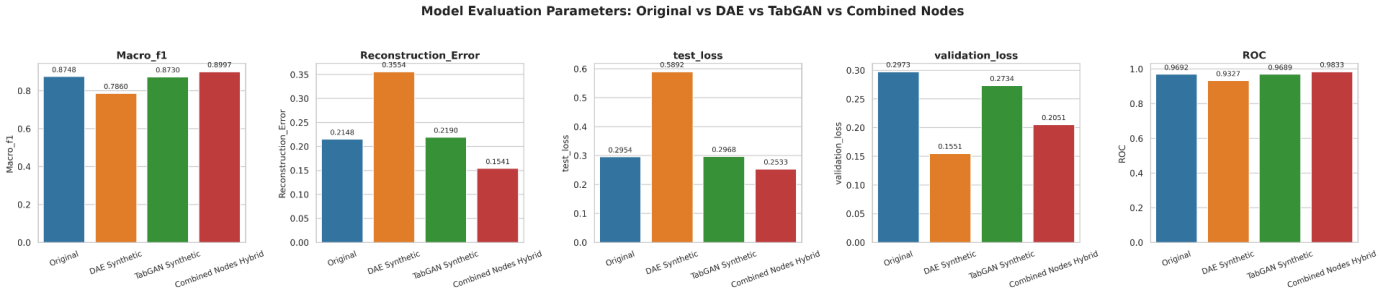
Datensatz im gesamt ist wie folgt aufgebaut: Grün: (None/Benign) Rot: (Syn-Flood) Blau: (Backdoor)



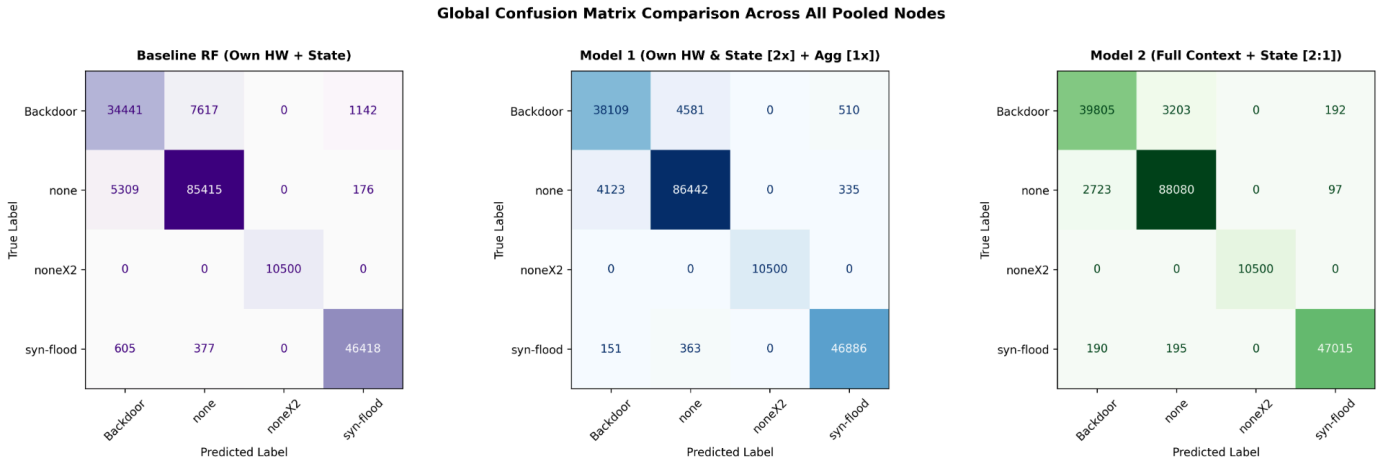
Der gemischte Datensatz (Original, DAE, TabGAN) hier Combinded Nodes genannt, im vergleich zu den reinen Oriignalen Datensatz und TabGAN bzw. DAE jeweils alleinstehend:



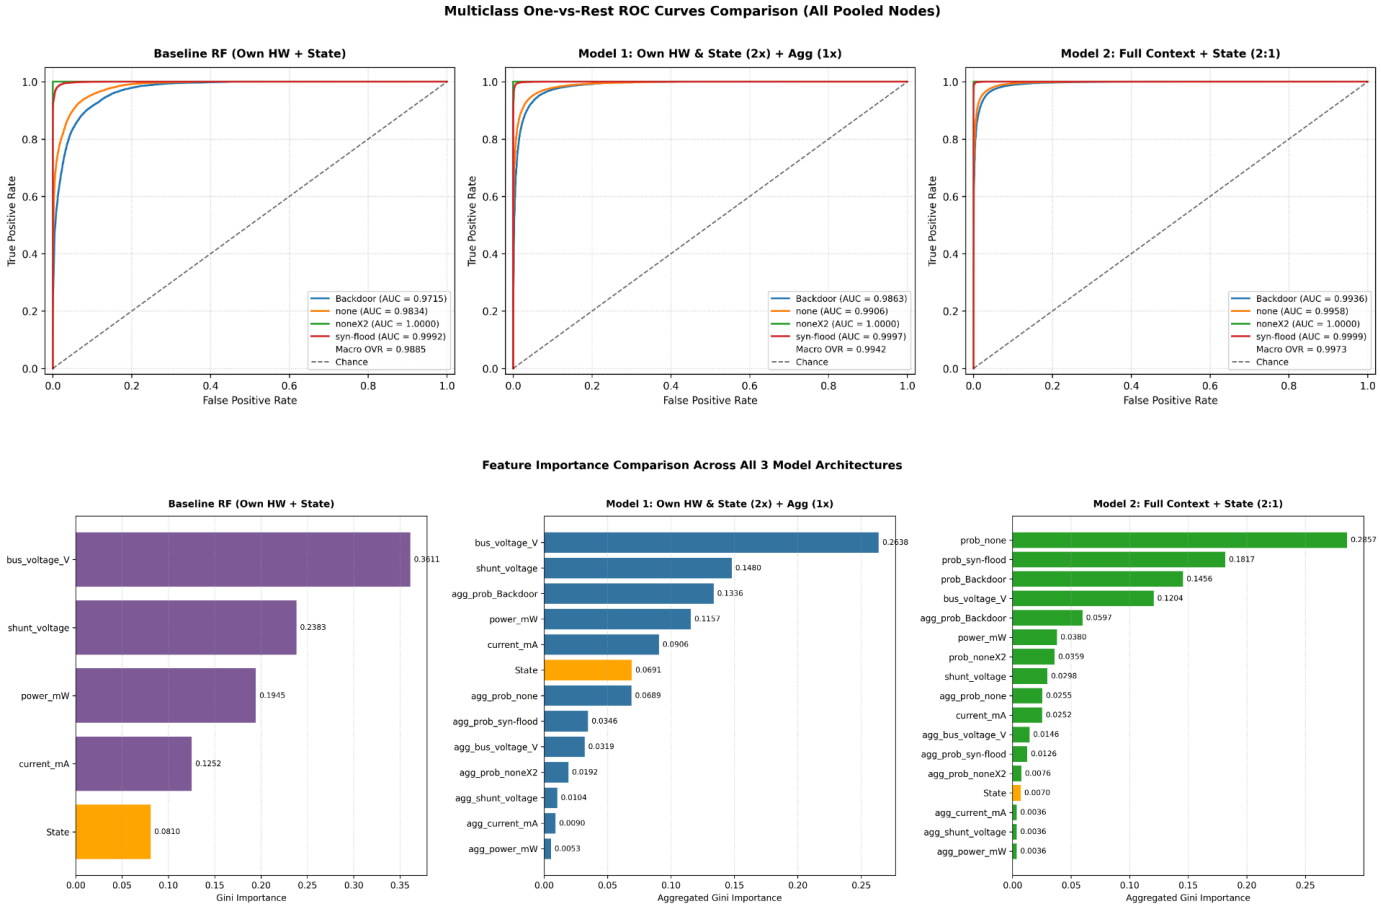




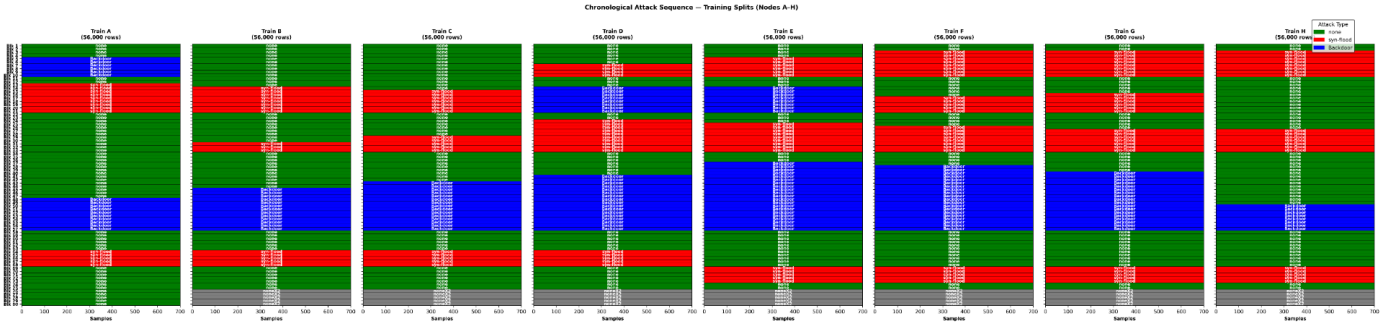
Nun Die modelle im vergleich Baseline: (Model welches nur die eigenen HW-daten auswertet), Model1: (Nuttz eigenen HW-Daten + Hardware und Attack_prob. Daten aus Agg-Report) Model2: (Eigenen HW-Daten, Eigenen Attack_prob, HW und attack_prob daten aus Agg_Report)



05_collaborative_report_aggregation.ipynb

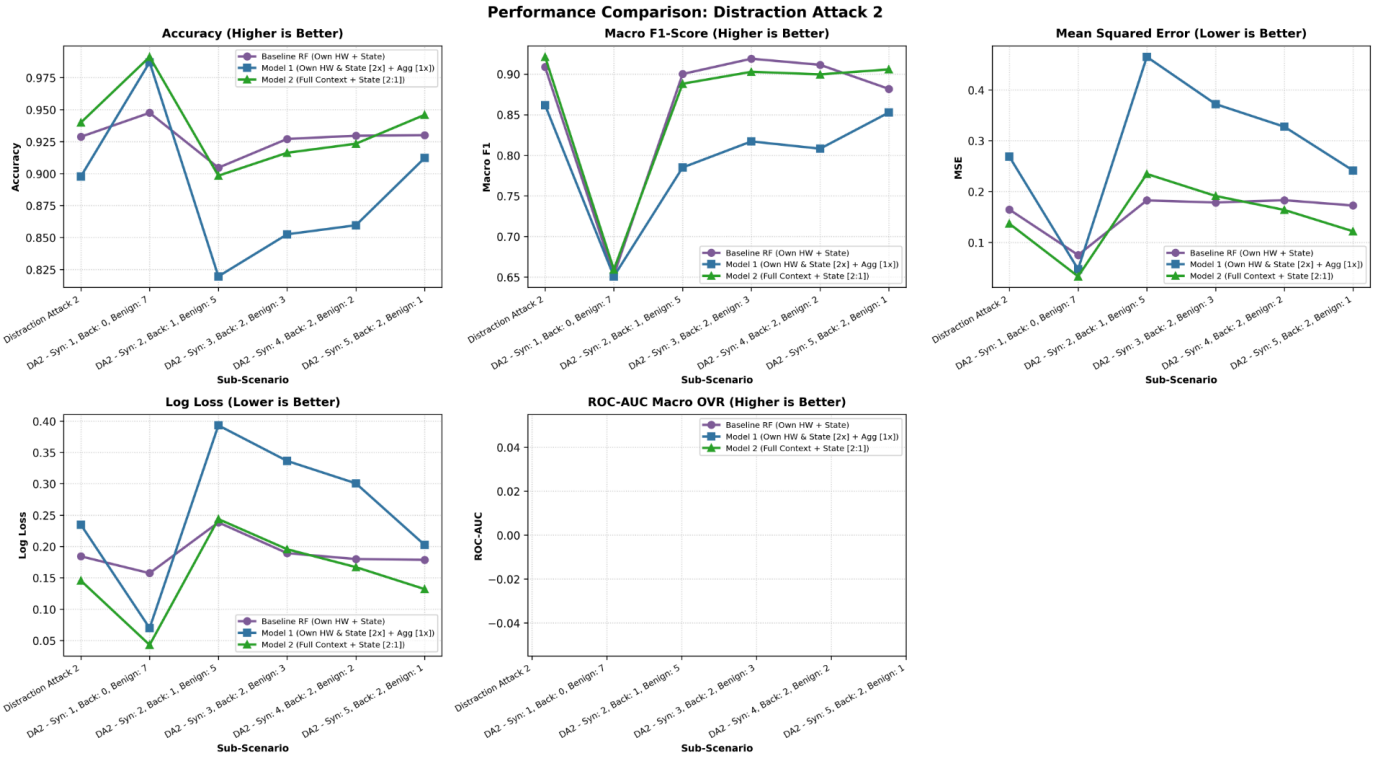


Angriffserkennung der verschiedenen Szenarien:



Die ersten Böcke wird einen Distraction syn-flood attack gemacht und nur auf einem ein Backdoor angriff

Danach nochmal das selbe nur das auf 2 Nodes ein Backdoor angriff gefahren wird
Dann ein Syn-Flood DDos angriff der mehrer nodes nach einander angreift
Das selbe mit einem Backdoor Angriff der sich über die zeit auf immer mehr Ladesäulen ausbreitet
Danach eine Cluster Shuffling Syn-Flood Attack
und als letztes none Leistungsschwankungen (grau) (muss ich nochmal anders klassifizieren als "none" oder weglassen)



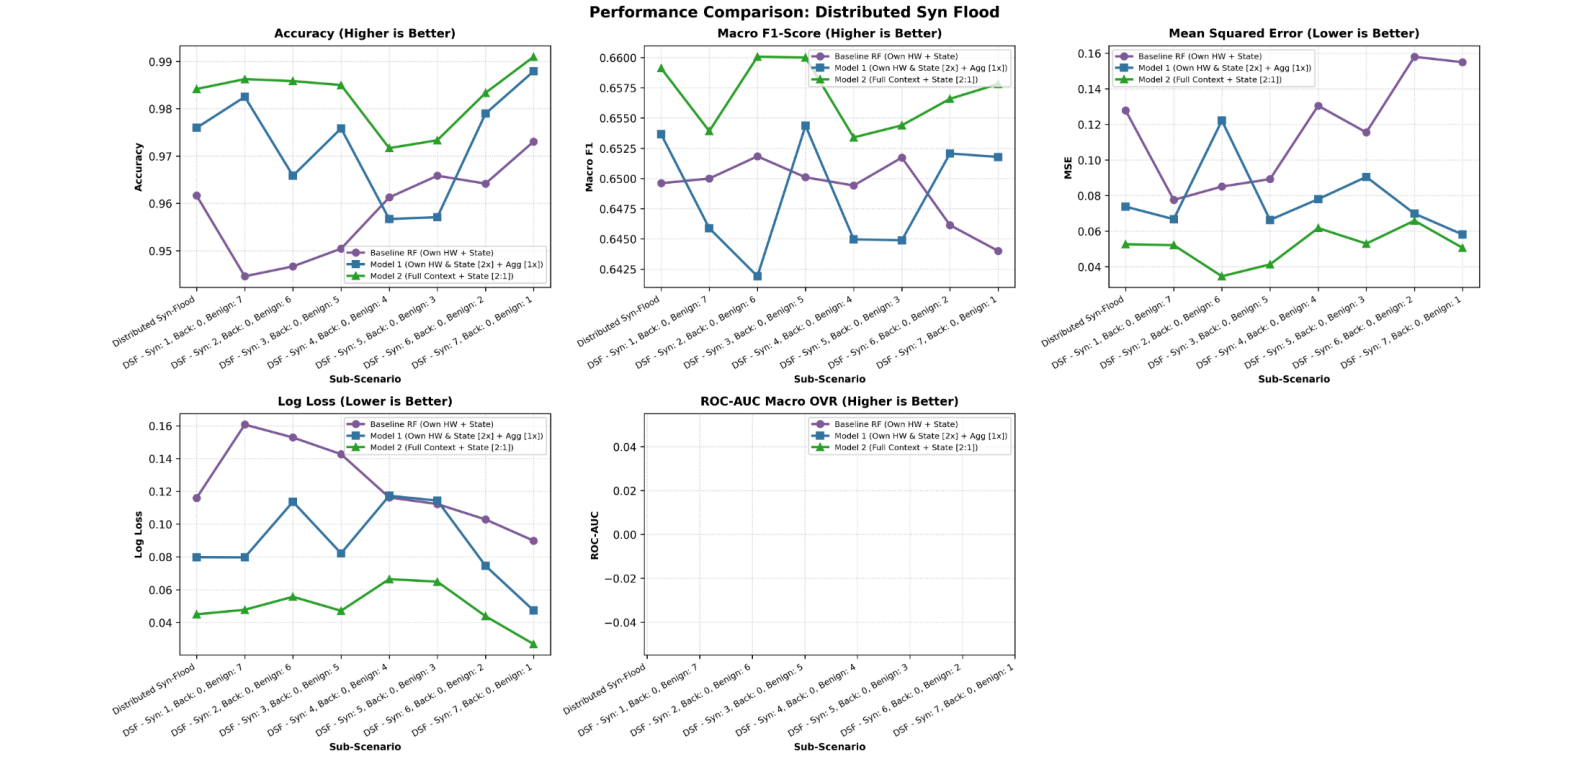
Berechnung des MacroF1-Score:

$$\mathrm{F1} = \frac{2 * \mathrm{TP}}{2 * \mathrm{TP} + \mathrm{FP} + \mathrm{FN}}$$

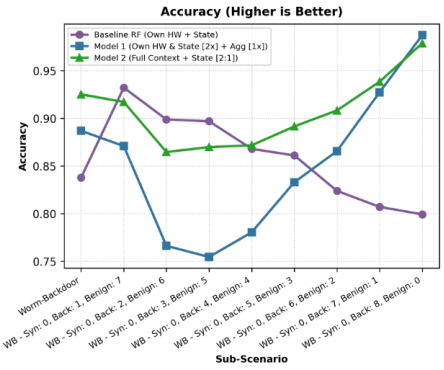
Where TP is the number of true positives, FN is the number of false negatives, and FP is the number of false positives. F1 is by default calculated as 0.0 when there are no true positives, false negatives, or false positives.

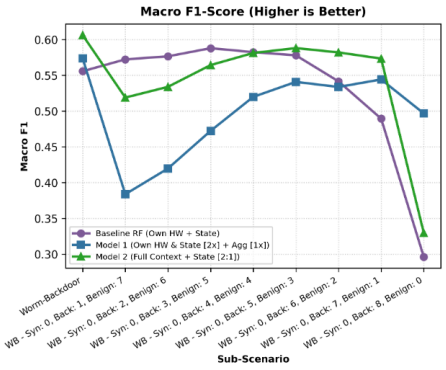
(quelle: scikit-learn)

Wenn None block alles richtig erkannt wird precision = 1.0 , wenn syn-flood alles erkannt wird Precision = 1.0, wenn backdoor nicht vorhanden ist ist es 0*0/0+0, und dann wird der schnitt von allen genommen also
1.0 + 1.0 + 0 / 3 = 0.66 deshalb der schlechte Macro F1-Score

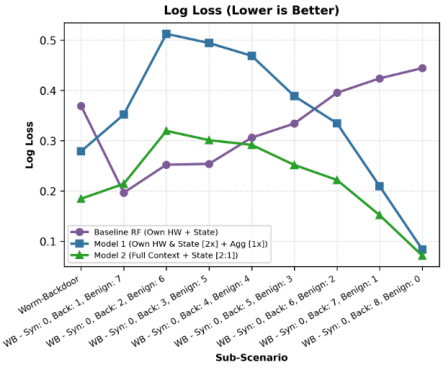

Performance Comparison: Distributed Syn Flood
Accuracy (Higher is Better)
Macro F1-Score (Higher is Better)
Mean Squared Error (Lower is Better)
Log Loss (Lower is Better)
ROC-AUC Macro OVR (Higher is Better)
Baseline RF (Own HW + State)
Model 1 (Own HW & State [2x] + Agg [1x])
Model 2 (Full Context + State [2:1])
Accuracy
Macro F1
MSE
Log Loss
ROC-AUC
Sub-Scenario
Distributed Syn-Flood
DSF - Syn: 1, Back: 0, Benign: 7
DSF - Syn: 2, Back: 0, Benign: 6
DSF - Syn: 3, Back: 0, Benign: 5
DSF - Syn: 4, Back: 0, Benign: 4
DSF - Syn: 5, Back: 0, Benign: 3
DSF - Syn: 6, Back: 0, Benign: 2
DSF - Syn: 7, Back: 0, Benign: 1

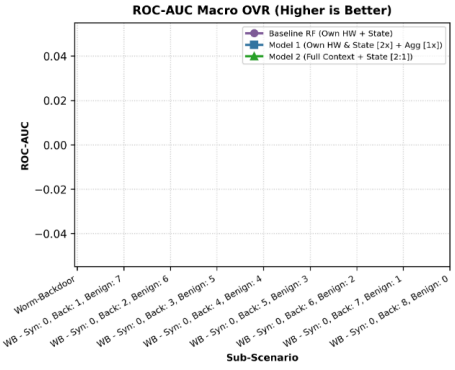
Performance Comparison: Worm Backdoor



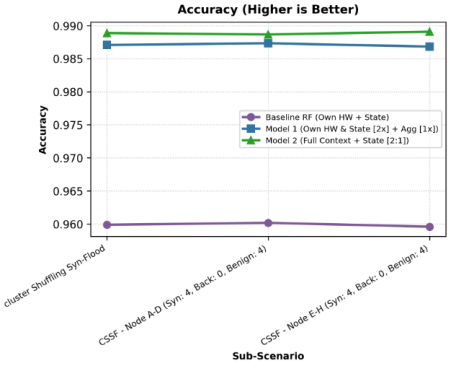


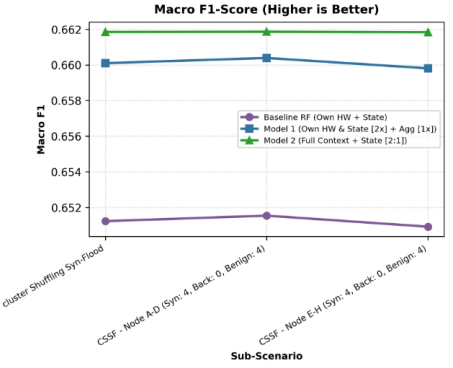


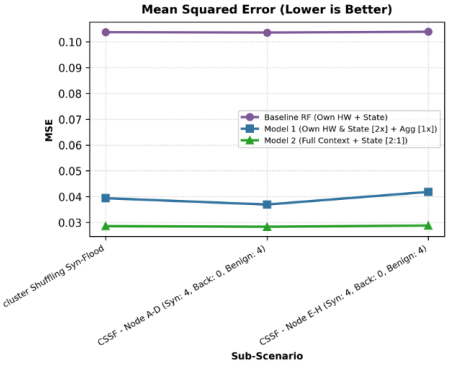


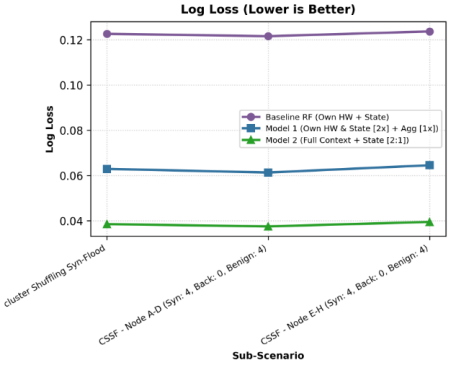


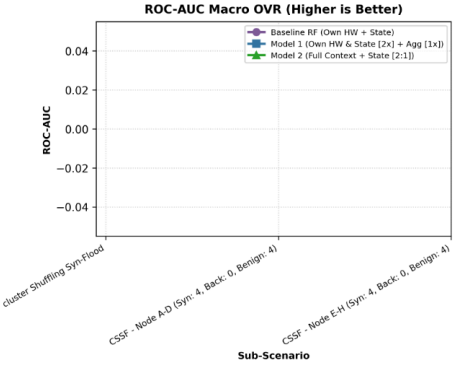
Performance Comparison: Cluster Shuffling Syn Flood

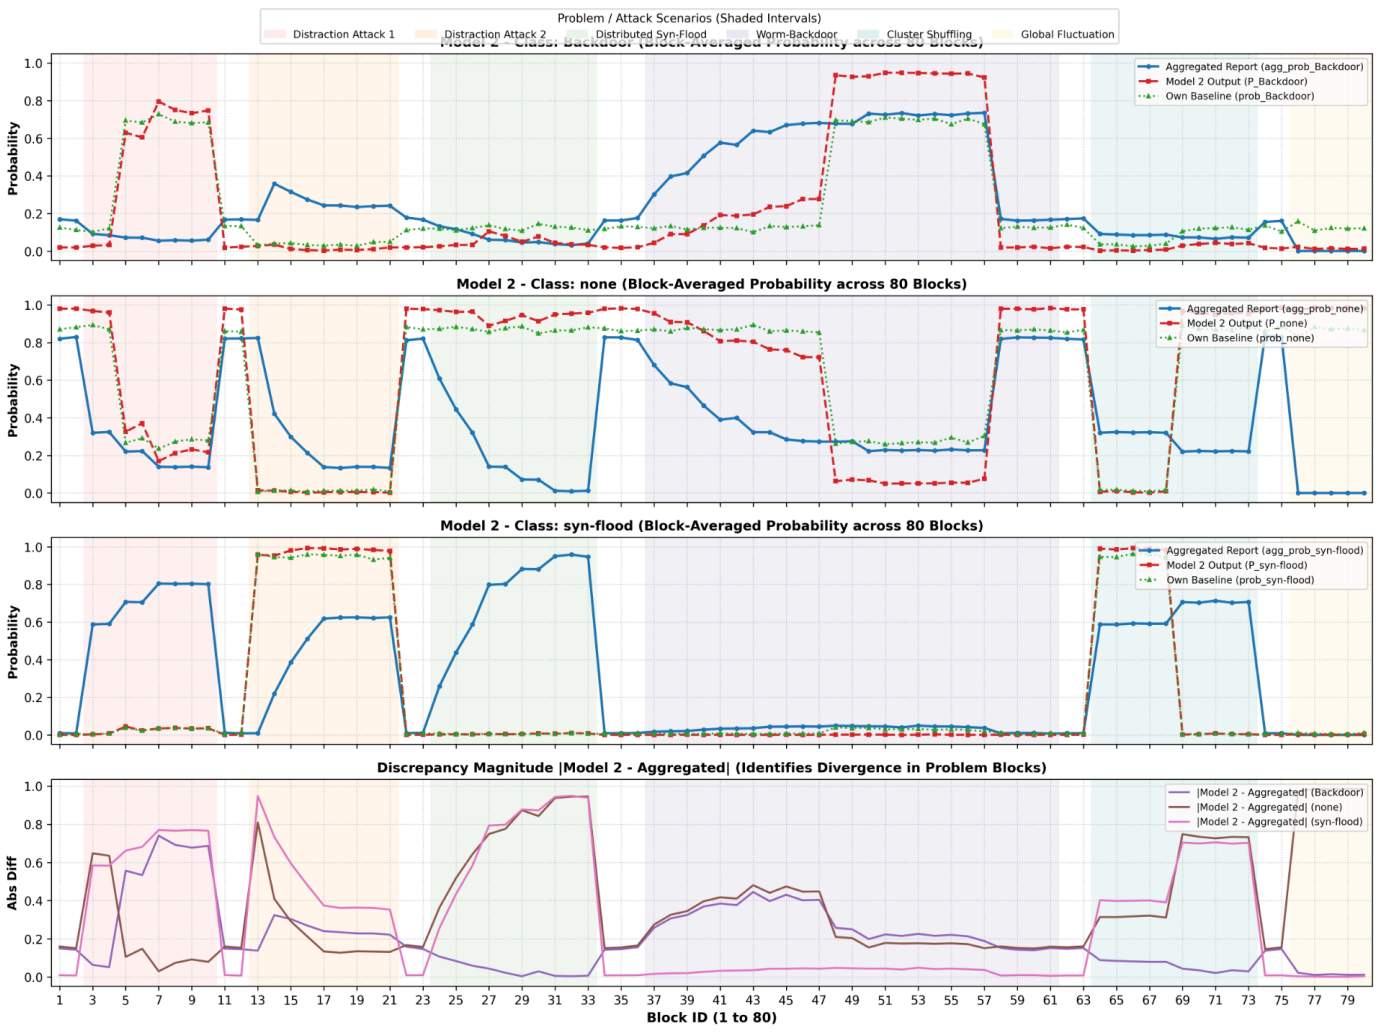


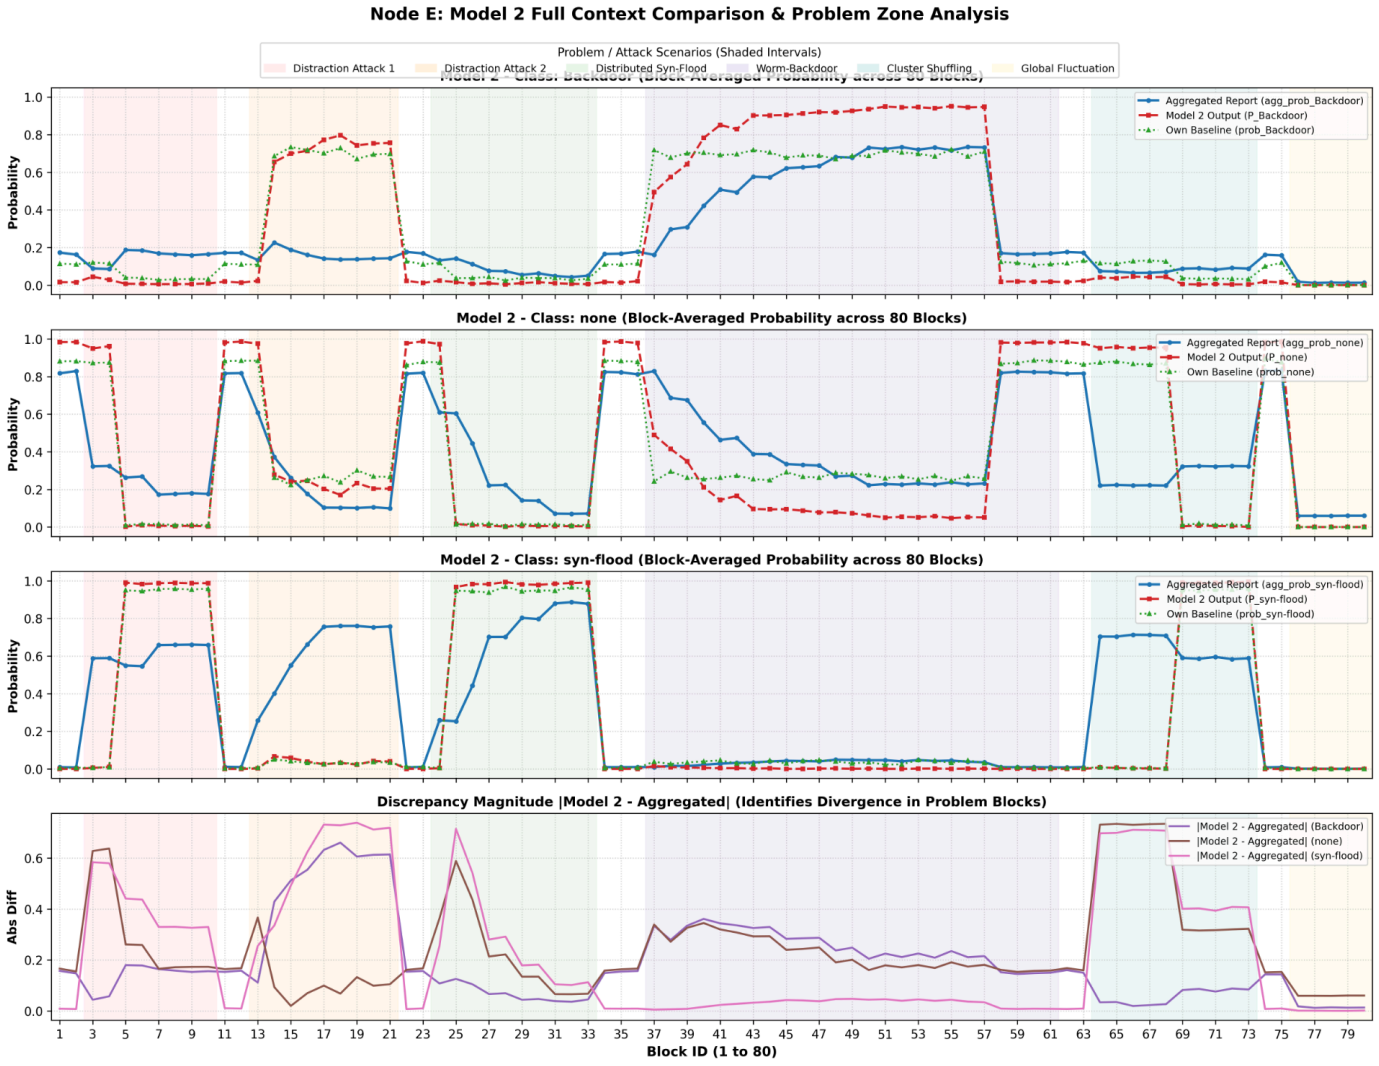




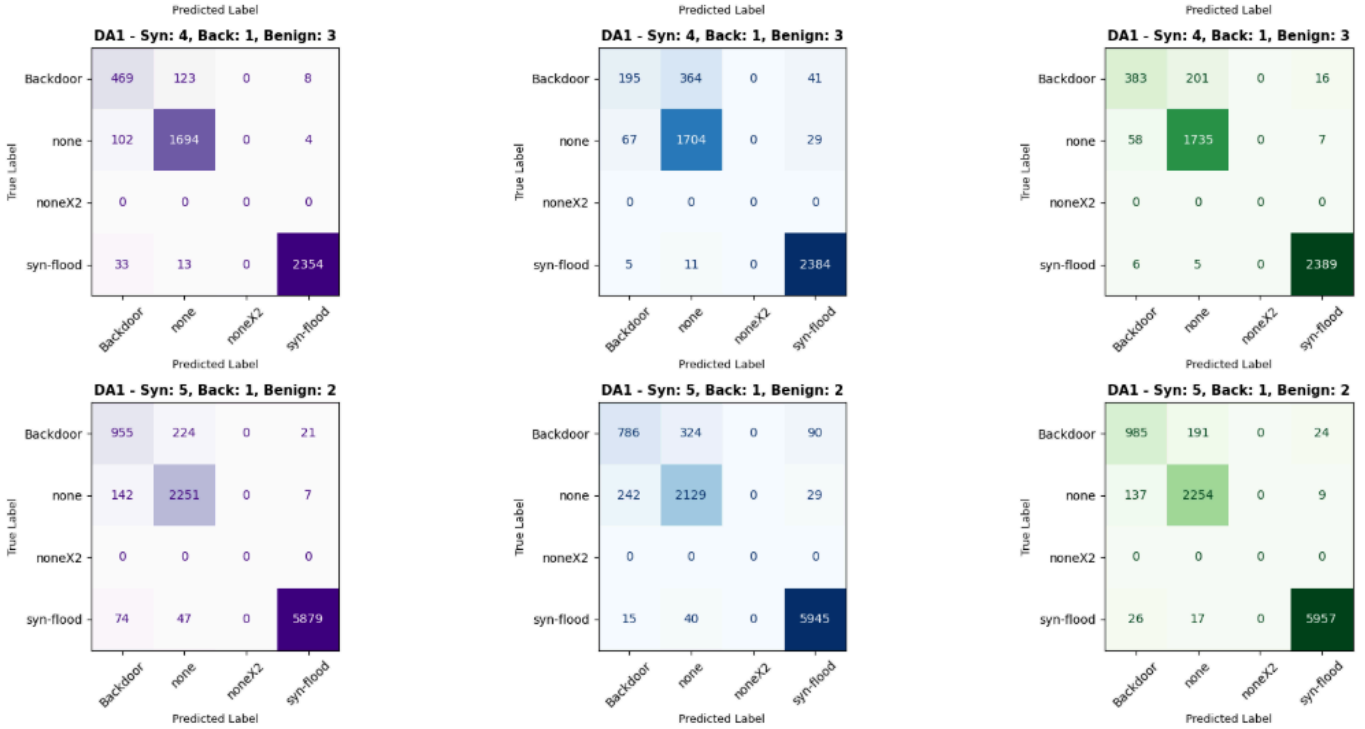


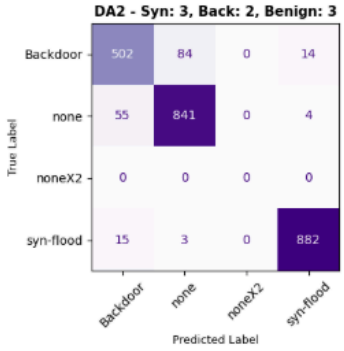


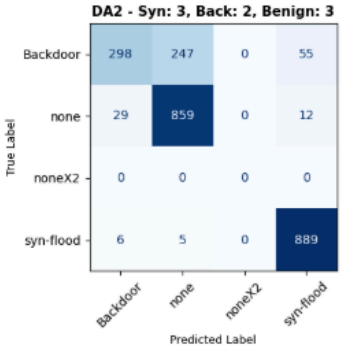

Node A: Model 2 Full Context Comparison & Problem Zone Analysis
Problem / Attack Scenarios (Shaded Intervals)
Distraction Attack 1
Distraction Attack 2
Distributed Syn-Flood
Worm-Backdoor
Cluster Shuffling
Global Fluctuation
Model 2 - Class: Backdoor (Block-Averaged Probability across 80 Blocks)
Aggregated Report (agg_prob_Backdoor)
Model 2 Output (P_Backdoor)
Own Baseline (prob_Backdoor)
Model 2 - Class: none (Block-Averaged Probability across 80 Blocks)
Aggregated Report (agg_prob_none)
Model 2 Output (P_none)
Own Baseline (prob_none)
Model 2 - Class: syn-flood (Block-Averaged Probability across 80 Blocks)
Aggregated Report (agg_prob_syn-flood)
Model 2 Output (P_syn-flood)
Own Baseline (prob_syn-flood)
Discrepancy Magnitude |Model 2 - Aggregated| (Identifies Divergence in Problem Blocks)
|Model 2 - Aggregated| (Backdoor)
|Model 2 - Aggregated| (none)
|Model 2 - Aggregated| (syn-flood)
Probability
Abs Diff
Block ID (1 to 80)

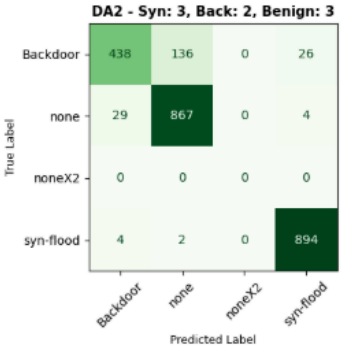


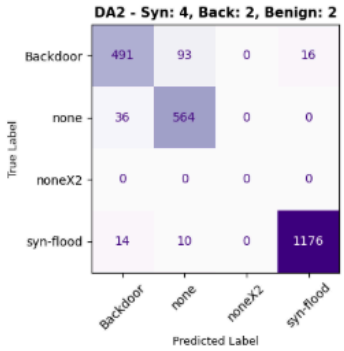
Daraus kann man lesen sehn das er sich bei der Distraction Backdoor erst sicher ist wenn Syn-Flood avg score hoch ist dann ist er sich auch sicherer wenn seinen eigenen Attack_prob_Backdoor hochgeht, und eine sichere Entscheidung trifft.

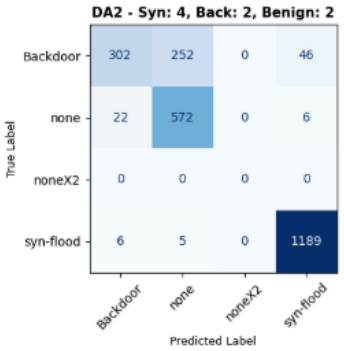


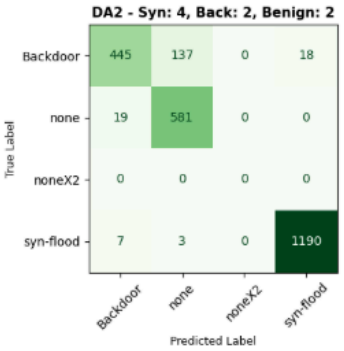


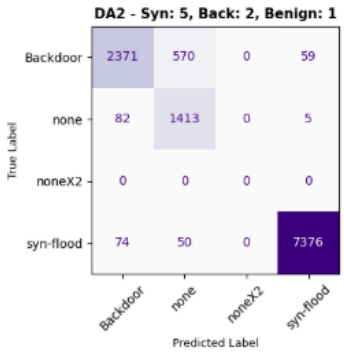


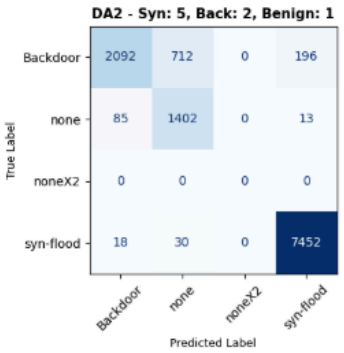


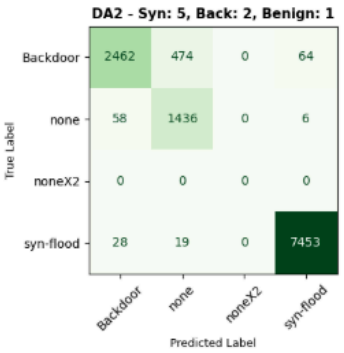






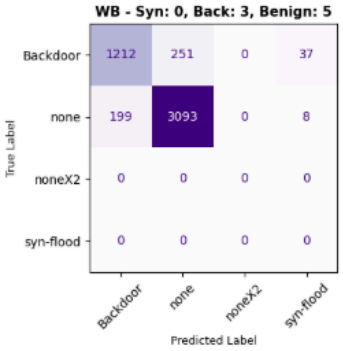


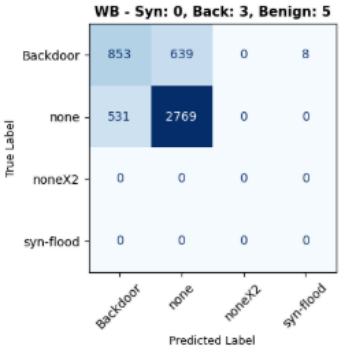


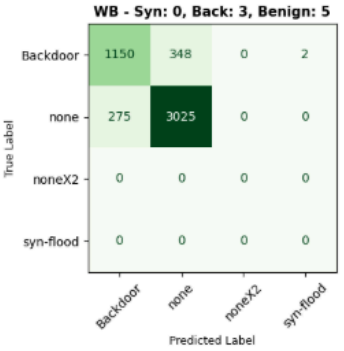


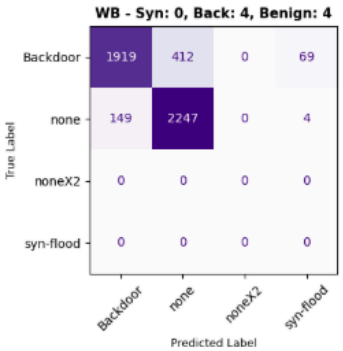
Auch hier syn-flood braucht einen deutlichen spike damit er Backdoor angriff und diese art von distraction erkennt. Weiterhin muss man zu gute halten, dass er syn-flood dauerhaft besser erkenntriffen werden.

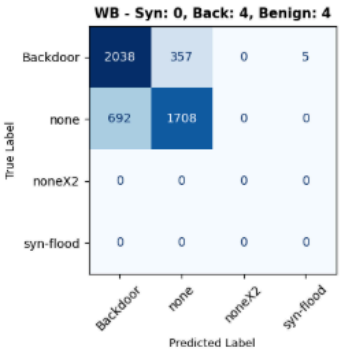
Bei Backdoor angriffen über verteiltes netzwerk ist der Sprung erst bei 50% der gesamten nodes infiziert:

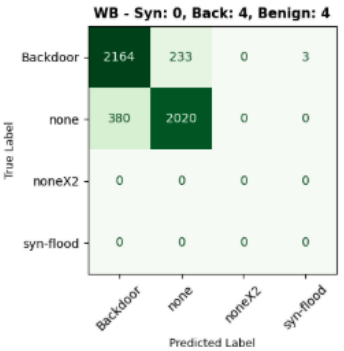




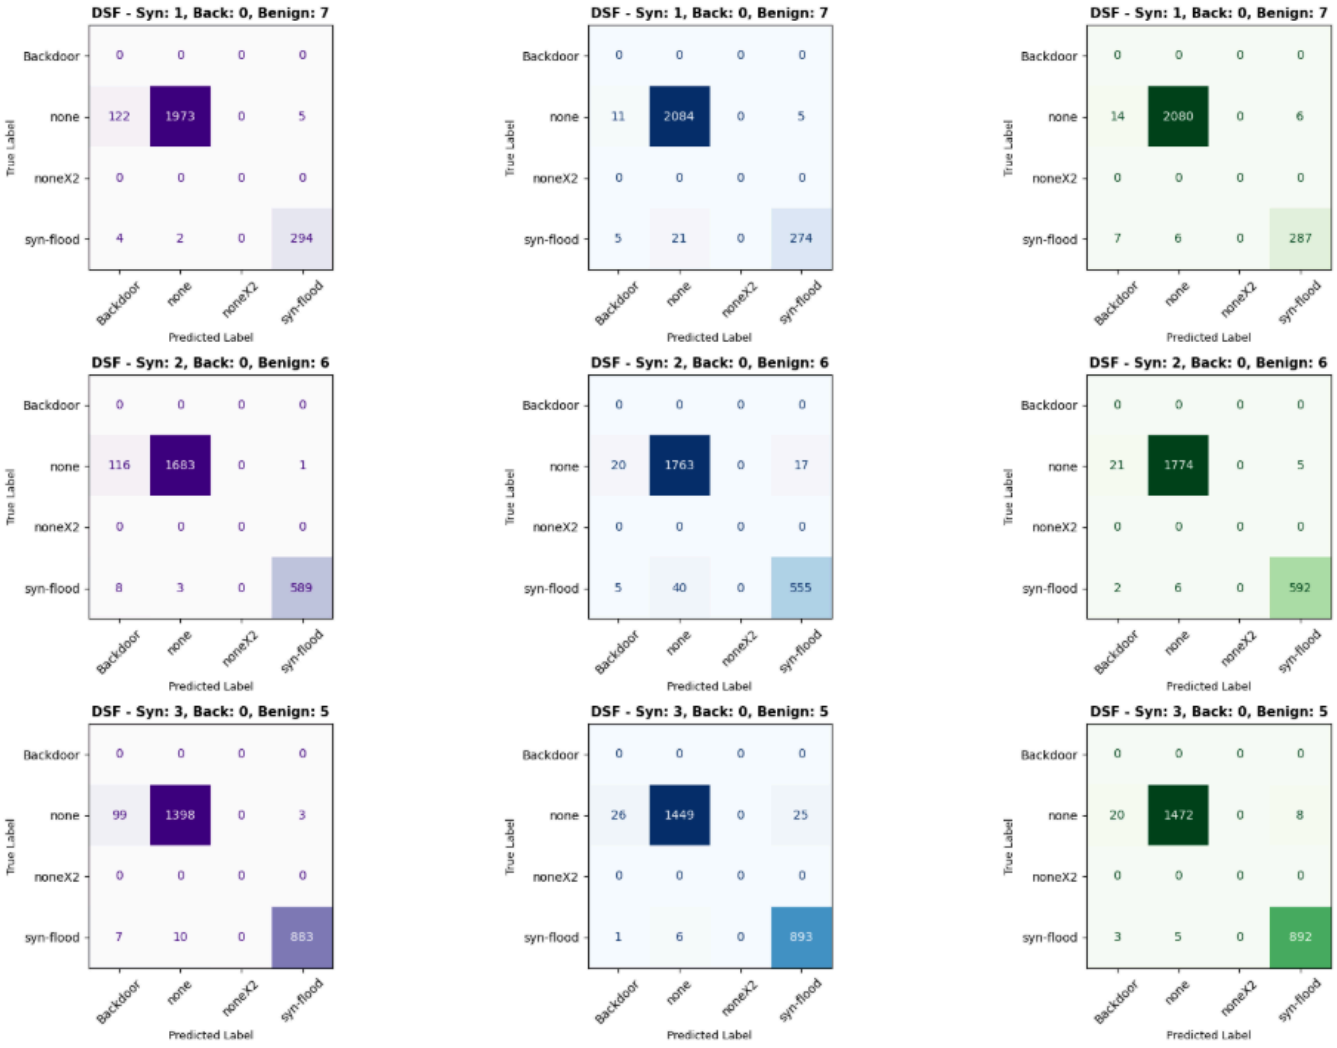




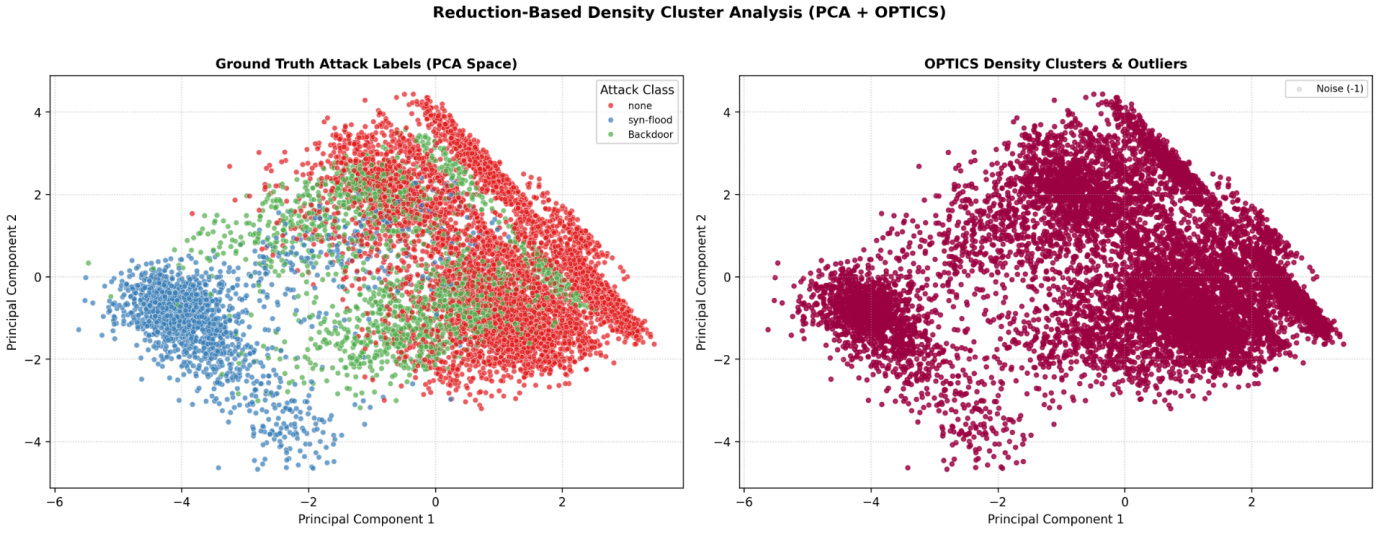




Bei Syn-Flood alleine liegt ohne weiteres rauschen ist die erkennungsrate durch den Agg report sogar noch besser



Die Muster insgesamt ist auch genau das was die bisherigen ergebnisse vermuten lassen, syn-flood hat eine deutliche eigenes cluster und benign zu backdoor unterscheided sich nur kaum:



train test los Baseline RF:

```
Final Train Log Loss:  0.192623
 Final Test Log Loss:   0.201272
```

Model 1:

```
Train Log Loss:        0.124317
```

```
Global Test Loss:      0.138893
```

Model 2:

```
Train Log Loss:        0.066727
```

```
Global Test Loss:      0.089103
```