Neighbor Context Detection Evaluation

Yannic Hanel
Department of Computer Science
Ostbayerische Technische Hochschule Regensburg
Regensburg, Germany
e-mail: yannic.hanel@st.oth-regensburg.de

***Abstract*—Entwurf später ergänzen: Forschungsfrage, Evaluationsaufbau, zentrale quantitative Ergebnisse und vorsichtige Schlussfolgerung.**

Keywords-Ladesäulen; Cybersicherheit; Intrusion Detection; Peer-to-Peer; synthetische Daten.

I. Einleitung

A. Inhaltliche Stichpunkte

- **Motivation**
  - Zunehmende Vernetzung von Ladeinfrastruktur für Elektrofahrzeuge (EVSE) und daraus entstehende Cybersicherheitsrisiken.
  - Im Datensatz werden acht Knoten (Node A bis H) und die Klassen Backdoor, syn-flood und "none" untersucht.
- **Problemstellung**
  - Lokale Beobachtungen eines einzelnen Knotens können Hinweise auf koordinierte oder über mehrere Knoten verteilte Angriffe verpassen.
  - Forschungsbedarf und Aussagen über bestehende IDS mit Literatur belegen; diese Begründung ist nicht durch die Evaluationsnotebooks allein abgedeckt.
- **Lösungsansatz**
  - Neighbor Context Detection: lokale Messwerte und Erkennungswahrscheinlichkeiten werden durch aggregierte Informationen anderer Knoten ergänzt.
  - Im ausgewerteten Aggregationslauf gehen die Informationen aller sieben übrigen Knoten ein; die genaue Topologie ist in Kapitel III zu klären.
- **Forschungsfrage**
  - Führt der Austausch von Kontextinformationen benachbarter Knoten in einem P2P-Netzwerk zu einer signifikant besseren Erkennungsleistung?
  - Die Notebook-Ergebnisse zeigen höhere Kennzahlen für das Full-Context-Modell; ein statistischer Signifikanztest ist dort jedoch nicht dokumentiert.
- **Beitrag der Arbeit**
  - Evaluation einer lokalen Baseline gegenüber Random-Forest-Modellen mit aggregiertem Nachbarschaftskontext.
  - Hybride Datengenerierung mit realen Daten sowie klassenspezifischen Anteilen von TabGAN- und DAE-Daten.
  - Evaluation über acht simulierte Knoten und mehrere Angriffsszenarien.

B. Noch zu erklären

- Was "signifikant" in der Forschungsfrage bedeutet und welche statistischen Tests oder Wiederholungen dazu noch durchgeführt werden.
- Ob die untersuchten Eingaben tatsächlich Netzwerkverkehr oder elektrische Betriebsmerkmale der Ladepunkte darstellen: Die Evaluationsnotebooks verwenden shunt_voltage, bus_voltage_V, current_mA, power_mW und State.
- Welche Aussagen durch eigene Messungen belegt werden und welche durch Literatur begründet werden müssen.

C. Grafikbedarf

- **Übersichtsdiagramm:** acht EVSE-Knoten, lokale Erkennung, Austausch aggregierter Kontextinformationen und die drei Zielklassen.

II. Grundlagen und verwandte Arbeiten

A. Inhaltliche Stichpunkte

- **Architektur von Ladesäulen**
  - Im Experiment repräsentieren Node A bis H acht Knoten.
  - Die verwendeten Merkmale sind vier elektrische Messwerte und der Betriebszustand State (idle oder charging).
  - Reale EVSE-Komponenten, Backend-Anbindung und Kommunikationspfade anhand geeigneter Quellen beschreiben; die Notebooks bilden keine vollständige physische EVSE-Architektur ab.
- **Bedrohungsmodell**
  - Zielklassen: Backdoor, syn-flood und "none" (benignes Verhalten).
  - In Notebook 07 werden unter anderem Distraction Attack 1/2, Distributed SYN Flood, Worm Backdoor und Cluster Shuffling SYN Flood als Szenariogruppen ausgewertet.
- **P2P-basierte Erkennung**
  - Verwandte Ansätze zum dezentralen Informationsaustausch und zur verteilten Anomalieerkennung recherchieren und gegenüber dem hier ausgewerteten Verfahren abgrenzen.

  - Konsensverfahren von einfacher gewichteter Merkmalsaggregation unterscheiden: Die Notebooks implementieren eine gewichtete Aggregation von Peer-Berichten, keinen dokumentierten Konsensalgorithmus.
- **Datenerweiterung in der Cybersicherheit**
  - TabGAN und Denoising Autoencoder (DAE) als Generatoren für strukturierte Daten einordnen.
  - Motivation für synthetische Beispiele und Risiken hinsichtlich Realitätsnähe, Klassenabdeckung und Evaluationsverzerrung belegen.

B. Noch zu erklären

- Herkunft und Bedeutung der Labels Backdoor und synflood sowie die konkrete Durchführung der jeweiligen Angriffe.
- Warum elektrische Betriebsmerkmale und State diese Angriffe erkennbar machen sollen, obwohl die verwendeten Features keine Netzwerkpaketmerkmale sind.
- Welche EVSE-Standards, P2P-Ansätze und Verfahren zur synthetischen Datengenerierung für diese Arbeit relevant sind; passende Quellen und eine Abgrenzung zum eigenen Beitrag ergänzen.

C. Grafikbedarf

- **Architekturskizze:** EVSE, lokale Sensorik/Erkennung und externe Kommunikationspartner; als konzeptionelle Darstellung kennzeichnen, falls nicht im Experiment implementiert.
- **Angriffsszenarien:** optional eine kleine Übersicht der Backdoor- und SYN-Flood-Szenarien aus Notebook 07.

III. Methodik: Neighbor Context Detection im P2P-Netzwerk

A. Inhaltliche Stichpunkte

- **Lokale Baseline**
  - Random-Forest-Klassifikator auf zusammengeführten Trainingsdaten der Knoten A bis H.
  - Eingaben: shunt_voltage, bus_voltage_V, current_mA, power_mW und State; Zielklassen Backdoor, none und syn-flood.
  - Lokale Modellwahrscheinlichkeiten für die Angriffsklassen werden als Grundlage für Peer-Berichte gespeichert.
- **Kontextaggregation**
  - Pro Zeitschritt aggregiert jeder Zielknoten Berichte der sieben übrigen Knoten; der Zielknoten selbst wird nicht als Peer gezählt.
  - Die Peer-Berichte werden anhand einer Sigmoid-Funktion gewichtet: Basisgewicht 1, Maximalgewicht 3, Steilheit 10 und Wendepunkt bei einer Angriffswahrscheinlichkeit von 0,5.
  - Aggregiert werden Peer-Messwerte und Peer-Klassifikationswahrscheinlichkeiten; die erzeugten Kontextmerkmale umfassen außerdem Gewichtssumme und Anzahl der beitragenden Peers.
- **Modellvarianten**
  - Model 1: eigene vier Messwerte, State und aggregierter Kontext (12 Eingabemerkmale).
  - Model 2: eigene Messwerte, State, eigene Klassenwahrscheinlichkeiten und aggregierter Kontext (15 Eingabemerkmale).
  - Vergleich mit Baseline ohne Kontext sowie mit einer zusätzlichen transformierten Baseline, bei der eigene und aggregierte Messwerte kombiniert werden.
- **Hypothese**
  - Kontextinformationen können bei verteilter Aktivität die Erkennung verbessern; ob dies Fehlalarme reduziert, ist separat anhand einer Falsch-Positiv-Rate zu prüfen.

B. Noch zu erklären

- Notebook 05 verwendet alle sieben anderen Knoten; eine räumliche oder logische Nachbarschaftstopologie mit weniger Peers ist nicht ersichtlich. Klären, ob das Experiment ein vollständiges Mesh oder ein abstrahiertes P2P-Modell darstellen soll.
- Begründen, warum die Gewichte von der Angriffswahrscheinlichkeit abhängen, und die Sigmoid-Gleichung sowie deren Parameter herleiten.
- Beschreiben, ob die aggregierten Merkmale in der Praxis über ein Netzwerk übertragen werden oder nur synchron aus vorbereiteten Datensätzen berechnet werden. Latenz, Paketformat, Ausfälle und Vertrauensannahmen sind in den Notebooks nicht experimentell belegt.
- Die Begriffe “Konsens” und “lokale Erkennung” präzisieren: Die Baseline wird laut Notebook 04 auf gepoolten Daten trainiert; sie ist daher nicht ohne Weiteres ein separat trainiertes Modell pro EVSE.
- Leakage-Schutz, Vorverarbeitung, Normalisierung und verwendete Modellparameter transparent dokumentieren.

C. Grafikbedarf

- **Datenflussdiagramm:** lokale Merkmale → Random-Forest-Wahrscheinlichkeiten → gewichtete Peer-Aggregation → Kontextmodell und Klassenvorhersage.
- **Netzwerkdiagramm:** Node A bis H und die tatsächlich verwendeten Peer-Verbindungen; nicht vor einer Klärung der Topologie als Ring oder anderes Nachbarschaftsmodell darstellen.

IV. Auswahl und Evaluierung synthetischer Datenerweiterung

A. Inhaltliche Stichpunkte

- **Vergleichsaufbau aus Notebook 01b**
  - Je ein Random-Forest-Modell wird mit Originaldaten, DAE-Daten, TabGAN-Daten und dem hybriden Datensatz der Knoten trainiert.

  - Alle vier Varianten werden laut Notebook auf demselben Original-Testdatensatz bewertet.
  - Macro-F1: Original 0,8748; DAE 0,7860; TabGAN 0,8730; Combined Nodes Hybrid 0,8890.
  - ROC-AUC: Original 0,9692; DAE 0,9327; TabGAN 0,9689; Combined Nodes Hybrid 0,9845.
  - Test Loss: Original 0,2954; DAE 0,5892; TabGAN 0,2968; Combined Nodes Hybrid 0,2682.
  - Die Notebook-Grafik zeigt für den hybriden Datensatz den besten Macro-F1- und ROC-AUC-Wert dieser vier Varianten.
- **Klassenabhängige Generatoranteile**
  - Vorgesehene Aufteilung der synthetischen Anteile: Backdoor 65 % TabGAN / 35 % DAE; none 55 % TabGAN / 45 % DAE; syn-flood 60 % TabGAN / 40 % DAE.
  - Die global gezählten Anteile im fertigen Datensatz weichen wegen der zusätzlichen Originaldaten ab: Backdoor 55,78 % TabGAN, 30,13 % DAE, 14,09 % Original; none 53,20 % TabGAN, 43,51 % DAE, 3,29 % Original; syn-flood 56,18 % TabGAN, 37,48 % DAE, 6,35 % Original.
  - Die Pipeline erzeugt 100 Blöcke je Knoten und jeweils 100 000 Zeilen pro Knoten (acht Knoten).
- **Begründung der Hybridwahl**
  - Notebook-Begründung: TabGAN erhält insgesamt höhere Anteile, weil es in den dortigen Modellvergleichen gegenüber DAE höhere Macro-F1-/ROC-AUC-Werte und niedrigere Fehlerwerte erzielt.
  - Für none wird der höhere DAE-Anteil mit der Abbildung von Sensorstatistiken sowie Idle-/Charging-Variabilität begründet; für Backdoor mit besser erhaltenen Korrelations- und Diskriminierungsmustern von TabGAN.
  - Diese klassenbezogenen Erklärungen anhand zusätzlicher Klassenmetriken oder Verteilungsvergleiche belegen; die globale Vergleichsgrafik allein zeigt keine klassenweise Generatorgüte.

B. Noch zu erklären

- Die Notebook-Spalte `Reconstruction_Error` wird mit `mean_squared_error` aus kodierten Klassenlabels und Vorhersagen berechnet. Das ist kein Rekonstruktionsfehler des Generators und sollte entsprechend umbenannt oder nicht als Fidelity-Metrik interpretiert werden.
- `validation_loss` stammt beim Random Forest aus Out-of-Bag-Wahrscheinlichkeiten; beschreiben, warum dieser Wert nicht mit einem separaten Validierungsdatensatz verwechselt werden darf.
- Die angegebenen Macro-F1-/ROC-AUC-Werte beschreiben Klassifikatoren, die auf den jeweiligen Datenvarianten trainiert und auf dem Original-Testdatensatz geprüft wurden. Das ist kein direkter statistischer Nachweis der Verteilungsähnlichkeit der Generatoren.
- Erklären, wie Originalbeispiele in die Blöcke injiziert werden und wie dadurch die tatsächlichen Quellenanteile pro Klasse entstehen.
- Begründen, ob die Datenquellenanteile und Modellvergleiche vor der finalen Auswahl festgelegt wurden; andernfalls mögliche Auswahlverzerrung diskutieren.

C. Grafikbedarf

- **Vorhanden:** evaluation/plots/model_evaluation_metrics.png für Macro-F1, Test Loss, ROC-AUC und die weiteren im Notebook dargestellten Kennzahlen.
- **Vorhanden:** evaluation/plots/feature_importance_comparison.png als Vergleich der Merkmalswichtigkeiten; nur verwenden, wenn die Interpretation für die Datengenerierung relevant ist.
- **Ergänzen:** Balken- oder Tabellenansicht der drei Datenquellenanteile je Klasse (TabGAN, DAE, Original).

V. Experimenteller Aufbau

A. Inhaltliche Stichpunkte

- **Netzwerk und Knoten**
  - Acht simulierte Knoten: Node A bis Node H.
  - In der dokumentierten Aggregation werden je Zielknoten sieben Peer-Berichte ausgewertet.
  - Die genaue Graphstruktur und ob reale Netzwerkkommunikation simuliert wird, vor der finalen Beschreibung festlegen.
- **Datensatz und Aufteilung**
  - Je Knoten 100 000 Zeilen in 100 Blöcken; je Block 70 % Training und 30 % Test.
  - Insgesamt: 560 000 Trainings- und 240 000 Testzeilen über alle Knoten.
  - Klassenverteilung im Training: none 305 900; syn-flood 149 100; Backdoor 105 000. Im Test: none 131 100; syn-flood 63 900; Backdoor 45 000.
  - Die Datensätze enthalten pro Klasse Original-, TabGAN- und DAE-Beispiele; die im fertigen Datensatz beobachteten Anteile stehen in Kapitel IV.
  - Aufteilung laut Notebook 02 blockweise mit 70/30-Split; genaue Reihenfolge und Zufallsbehandlung der Zeilen dokumentieren.
- **Merkmale und Klassen**
  - Numerische Merkmale: shunt_voltage, bus_voltage_V, current_mA und power_mW; zusätzlich State.
  - Zielklassen: Backdoor, none und syn-flood.
- **Varianten und Metriken**
  - Primärer Notebook 07-Vergleich auf 240 000 Testfällen: Baseline ohne Kontext gegenüber Model 2 mit Full Context + State.
  - Baseline: Accuracy 0,930625, Macro-F1 0,911805, Weighted-F1 0,928974, Log Loss 0,182478 und ROC-AUC (Macro OVR) 0,986353.

  - Model 2: Accuracy 0,962204, Macro-F1 0,953685, Weighted-F1 0,961924, Log Loss 0,098996 und ROC-AUC (Macro OVR) 0,994932.
  - Zusätzlich Precision, Recall und F1 je Klasse sowie Konfusionsmatrizen und ROC-Kurven auswerten.

B. Noch zu erklären

- Notebook 02 teilt innerhalb 1000-Zeilen-Blöcken auf; erläutern, ob zeitlich benachbarte Zeilen in Training und Test landen können und wie sich dies auf die Unabhängigkeit der Testdaten auswirkt.
- Die 240 000 Testzeilen stammen aus den finalen Knoten-Datensätzen mit gemischten Datenquellen. Von dem separaten Original-Testdatensatz aus Notebook 01b unterscheiden und die jeweilige Verwendung erklären.
- Die 100 000 Zeilen je Knoten und die Klassenverteilungen mit den erzeugten Szenarien und Originaldaten abgleichen.
- Hardware, Softwareversionen, RF-Parameter, Zufalls-Seeds und konkrete Normalisierungsschritte nachvollziehbar angeben.
- Precision, Recall, F1 und ROC-AUC sind in den Ergebnisnotebooks ausgewiesen; eine Falsch-Positiv-Rate und ein Signifikanztest sind dort nicht direkt ausgewiesen und müssen gegebenenfalls ergänzt werden.

C. Grafikbedarf

- **Vorhanden:** evaluation/plots/test_attack_sequence_nodes_a_h.png zur zeitlichen Einordnung der Testblöcke; Trainingsplot nur bei zusätzlichem Erkenntniswert verwenden.
- **Erstellen:** Netzwerkdiagramm mit Node A bis H und der tatsächlich genutzten Peer-Verbindung.
- **Erstellen:** übersichtliche Tabelle oder Grafik mit Klassenverteilung und Datenquellen im Trainings- und Testsatz.

VI. Ergebnisse und Diskussion

A. Inhaltliche Stichpunkte

- **Baseline gegenüber Full Context**
  - Im Notebook 07 steigt Macro-F1 von 0,911805 (Baseline) auf 0,953685 (Model 2); Accuracy steigt von 0,930625 auf 0,962204 und ROC-AUC von 0,986353 auf 0,994932.
  - Log Loss sinkt von 0,182478 auf 0,098996.
  - Diese Werte sprechen im ausgewerteten Testlauf für bessere Klassifikation mit Full Context. Eine statistische Signifikanz ist damit ohne zusätzliche Tests nicht belegt.
- **Ergebnisse nach Klasse**
  - Backdoor: Recall 0,758200 → 0,880133; F1 0,810302 → 0,899922.
  - none: Recall 0,963883 → 0,975301; F1 0,944577 → 0,967988.
  - syn-flood: Recall 0,983818 → 0,993130; F1 0,980535 → 0,993145.
  - Backdoor weist in der Baseline den niedrigsten Recall auf und zugleich den größten absoluten Recall-Anstieg im Full-Context-Modell.
- **Zusätzliche Modellvariante**
  - Die transformierte Baseline, bei der eigene Merkmale doppelt so stark wie aggregierte Merkmale gewichtet werden (Verhältnis 2:1), erreicht Accuracy 0,706217, Macro-F1 0,691625 und ROC-AUC 0,870686.
  - Als separate Ablation/Transformation einordnen; nicht mit der Baseline ohne Kontext oder mit Model 1 gleichsetzen.
- **Szenarien und Datenqualität**
  - Notebook 07 erzeugt Szenariovergleiche für Distraction Attack 1/2, Distributed SYN Flood, Worm Backdoor und Cluster Shuffling SYN Flood.
  - Notebook 01b zeigt beim hybriden Trainingsdatensatz gegenüber Originaltraining höhere Macro-F1- und ROC-AUC-Werte auf dem dort verwendeten Original-Testdatensatz; diese Datengenerierungs-Evaluation von der P2P-Evaluation getrennt diskutieren.

B. Noch zu erklären

- Die Falsch-Positiv-Rate ist nicht direkt in der Notebook-Tabelle enthalten. Aus Konfusionsmatrizen je Klasse berechnen und die Definition für das Mehrklassenproblem angeben, bevor Robustheit gegenüber Sensitivität bewertet wird.
- Für die Forschungsfrage den Unterschied zwischen beobachtetem Leistungsanstieg und statistischer Signifikanz herausarbeiten; gegebenenfalls gepaarte Tests oder Wiederholungen ergänzen.
- Model 1 in Notebook 06 wird mit 24 000 Testfällen je Knoten (192 000 insgesamt) berichtet, während der primäre Vergleich in Notebook 07 30 000 je Knoten (240 000 insgesamt) verwendet. Diese Auswertungen nicht direkt vermischen; kanonische Testmenge und Modellvariante festlegen.
- Die Szenarioplot-Ergebnisse pro Modell und Angriff erklären; keine Aussagen über einzelne Szenarien aus der aggregierten Gesamtmetrik ableiten.
- Für den Hybrid-Datensatz erklären, ob die Verbesserung aus Datenvielfalt, Datenmenge oder einer anderen Klassenverteilung resultiert; dafür sind kontrollierte Ablationen erforderlich.

C. Grafikbedarf

- **Vorhanden:** evaluation/plots/confusion_matrices_comparison_all_models.png für den Hauptvergleich.
- **Vorhanden:** evaluation/plots/roc_curves_comparison_all_models.png zur Darstellung der ROC-Kurven.
- **Vorhanden:** evaluation/plots/scenarios_all_confusion_matrices_grid.png und die vorhandenen Szenariovergleiche im Ordner evaluation/plots/.

- **Erstellen:** Balkendiagramm für klassenweise Precision, Recall und F1; optional Falsch-Positiv-Rate nach deren Berechnung ergänzen.

VII. Fazit und Ausblick

A. Inhaltliche Stichpunkte

- **Kernfrage beantworten**
  - Im Notebook 07 erzielt Model 2 mit Full Context im betrachteten 240 000-Zeilen-Testlauf höhere Gesamtwerte als die Baseline: Macro-F1 0,953685 statt 0,911805, ROC-AUC 0,994932 statt 0,986353.
  - Vorsichtige Schlussfolgerung: In dieser Evaluation verbessert sich die beobachtete Erkennungsleistung. Eine statistisch signifikante Verbesserung ist ohne Signifikanztest nicht belegt.
- **Bedeutung der Methodik**
  - Die hybride Pipeline kombiniert reale Messreihen mit klassenspezifischen TabGAN- und DAE-Anteilen.
  - Im separaten Generatorvergleich erzielt der Combined-Nodes-Hybrid Macro-F1 0,8890 und ROC-AUC 0,9845 auf dem Original-Testdatensatz.
  - Empirische Begründung der Generatorwahl und unabhängige Testdaten als zentrale Voraussetzungen der Aussagekraft hervorheben.
- **Grenzen und zukünftige Arbeit**
  - Der aktuelle Aufbau umfasst acht simulierte Knoten; Skalierung auf größere Netzwerke untersuchen.
  - Physische Ladesäulen und echte Kommunikationsbedingungen sind noch zu evaluieren.
  - Latenz, Bandbreite, Ausfälle, Datenschutz und manipulierte Peer-Berichte als offene Fragestellungen aufnehmen.
  - Fehlende Signifikanzanalyse und noch zu berechnende Falsch-Positiv-Rate als Grenzen der vorliegenden Auswertung benennen.

B. Noch zu erklären

- Die Forschungsfrage anhand des vollständigen, einheitlichen Hauptvergleichs beantworten und dabei keine statistische Signifikanz behaupten, solange sie nicht getestet wurde.
- Abgrenzung der zwei Evidenzstränge: Generatorvergleich auf einem separaten Original-Testdatensatz und P2P-Modellvergleich auf den zusammengeführten Knotentestdaten.
- Grenzen der Übertragbarkeit von synthetischen/simulierten Daten auf reale EVSE und Einsatzbedingungen erläutern.

C. Grafikbedarf

- Keine neue Ergebniskurve nötig; auf die Hauptvergleichstabelle und die kompakte Metrikgrafik in Kapitel VI verweisen.
- Optional eine abschließende Übersicht mit Forschungsfrage, Kernergebnis, Einschränkungen und nächsten Schritten.